

2022 – 2 휴먼 인터페이스 미디어

과제 1 – 같은 모양 찾기



Cross - Correlation Measuring

20173709 소프트웨어학부

나원후

I. 서론

지난 수업 시간 동안 같은 객체를 찾는 방법에 대해서 배웠다. 가장 큰 분류로는 Convolution 을 통한 방법과 Cross - correlation 을 통한 방법이 있다. 본 과제 수행물에서는 이미지에서 패치를 직접 crop 하여, 그 패치와 “같은 모양 찾기” 를 수행한다.




그림 1. “같은 모양 찾기”를 수행할 이미지




그림 2. 이미지에 존재하는 객체

II. 이론적 배경

2.1 Convolution

Convolution (합성곱) 은 이미지 프로세싱과 인공신경망 모델링에서 많이 쓰이는 개념이다. 합성곱은 하나의 함수와 또 다른 함수를 반전 이동한 값을 곱한 다음, 구간에 대해 적분하여 새로운 함수를 구하는 수학 연산자이다. 합성곱을 수행할 때 한 함수를 반전시킨다는 점에서 교환법칙이 가능해진다.

$$(f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau \quad (1)$$

$$(g * f)(t) = \int_{-\infty}^{\infty} f(t - \tau)g(\tau)d\tau \quad (2)$$

$$(g * f)(t) = \int_{-\infty}^{\infty} g(\tau)f(t - \tau)d\tau \quad (2)$$

(1)의 τ 에 $t - \tau$ 를 넣으면 (2)의 형태가 된다. (2)의 형태는 결국 (3)의 형태와 같다. 즉, 교환 법칙이 성립한다. Convolution 은 반전된 함수와 원본 함수의 Cross-correlation 이라 할 수 있다.

2.2 Cross-correlation

Cross-correlation (교차 상관)은 신호처리에서 주로 쓰이는 개념이다. 교차 상관은 두 series 의 유사성의 척도이다.

$$(f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t)d\tau \quad (4)$$

이는 Convolution 과는 반대로 하나의 함수를 반전하지 않고 두 함수 모두 그대로 사용한다. 이미지를 반전시키지 않기 때문에 정렬된 이미지 안에서 이미지 유사도를 찾는데 쓴다.

2.3 cv2

cv2 (open cv)는 imread 를 통해 이미지를 읽어오며 3 채널 numpy 행렬로 읽어온다. 이때 각 채널은 RGB 순이 아닌 BGR 순으로 되어있다. 이미지가 numpy array 형식이기 때문에 image processing 연산을 쉽게 구현할 수 있다.

III. 구현 내용

3.1 Convolution 과 Cross-correlation 의 차이

이미지 연산에서 Convolution 과 Cross-correlation 의 차이는 Patch 를 함수 f 로 보았을 때, 패치를 좌우 반전을 하고 연산을 하는가, 아닌가에 있다. 그림 1 을 보았을 때 같은 객체인 경우 모두 같은 모양으로 존재한다. 즉, 만약 Convolution 을 적용하여 이미지 유사도를 측정한다면 그림 2 의 (a)

의 경우 좌우 반전을 했을 때 더 많이 겹치는 그림 2 의 (d) 와 유사도가 더 높게 나올 수 있다. 이렇게 이미지가 정렬되어 있는 상태에서 “같은 그림 찾기”는 Cross-correlation 으로 수행되어야 한다.

3.2 Code outline

코드의 구성은 Cross-correlation 을 계산하는 correlation.py, 이미지를 정규화하는 normalize.py, 결과를 종합하여 보여주는 show_output.py, 그리고 모든 함수를 종합하여 사용하는 main.ipynb 로 이루어져 있다.

3.1 correlation.py

이 모듈 안에는 3 가지 함수가 구현되어 있다. 각각의 함수가 수행하는 일은 다음과 같다.

- correlation (image, patch)

이미지를 순회하며 patch 와 이미지의 Cross-correlation 값을 구한다. 리턴 값은 patch 와 이미지가 겹치는 영역의 픽셀 값을 element-wise 하게 모두 곱하고 sum 한 값들의 2 차원 배열이다. overflow 를 막기 위해서 데이터 타입을 float64 로 형변환하여 값을 저장한다.

- three_channel_correlation (image, patch)

이미지는 총 3 개의 채널로 이루어져있다. 따라서 correlation 값도 총 3 가지가 나오며 three_channel_correlation 은 총합을 반환한다. 본 과제물에서는 이 리턴값을 사용한다.

- convolution_patch (image)

이미지의 좌우를 반전해 convolution 을 계산 가능하도록 한다. Convolution 을 계산하고 싶다면 패치를 변환한 후 three_channel_correlation 함수에 순회할 이미지와 함께 파라미터로 넣어준다.

3.2 normalize.py

더 좋은 결과를 얻기 위해서는 이미지 전처리, 정규화가 필수적이다. 이 모듈에서는 이미지 전처리에 관한 5 가지 함수를 제공한다.

- no_normalization (image)

이미지의 데이터 타입만 float64 로 변경해주고 픽셀에 아무런 연산을 하지 않는다. 이미지의 기본 데이터 타입은 BYTE 로, 형변환을 하지 않으면 데이터 손실이 일어날 수 있다.

- normalize_subtraction (image)

이미지의 모든 픽셀에서 128 을 빼준다. 한 픽셀의 값의 분포는 0 ~ 255 이므로 의도적으로 median 값을 빼주어 더 좋은 결과를 기대할 수 있다. 이때 파라미터로 들어오는 image 는 numpy array 로 – 연산을 하면 모든 픽셀에서 연산이 이루어진다.

- normalize_pixel (image)

이미지의 모든 픽셀 값을 해당 이미지의 높이 * 너비만큼 나눈 값을 반환한다.

- normalize_reverse (image)

이미지의 모든 픽셀을 255 에서 빼주어 반전된 이미지를 구한다. Cross-correlation 을 구할 때 패치와 이미지가 겹치는 부분의 픽셀들을 element-wise 하게 곱하여 모두 sum 하게 되는데, 이미지가 하얀 부분의 픽셀 값은 RGB 모두 255 로 항상 값이 높게 나오게 된다. 이를 방지하기 위해서 이미지 반전을 활용할 수 있다.

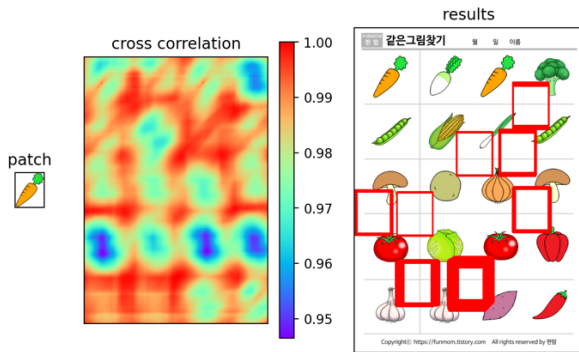
- normalize_0to1 (image)

이미지의 픽셀 분포를 0 에서 1 사이의 값으로 정규화한다. 이미지가 음수 값을 가질 것을 대비해 모든 값에서 이미지의 최소값을 더한 뒤, 그 이미지의 최댓값으로 나눈다.

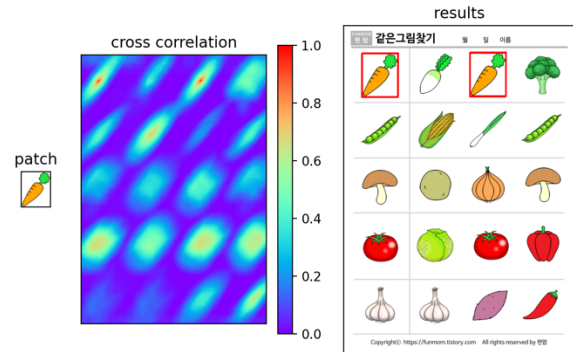
3.3 show_output.py

해당 모듈에서는 patch, image, output, threshold 값을 받아 결과를 출력한다. Output 은 correlation 값을 계산한 2 차원 1 채널 numpy array 로, 이 값들 중 threshold 보다 높은 값에 빨간 박스를 생성하여 “같은 모양 찾기” 를 수행한다.


IV. 결과 및 평가



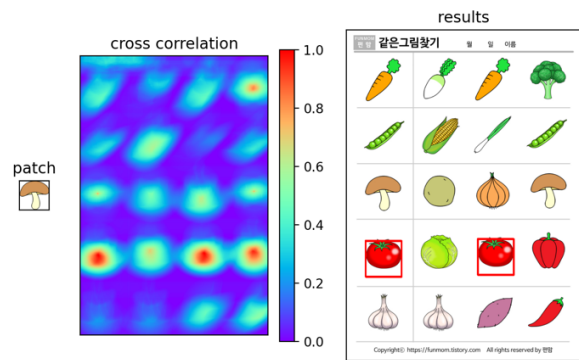
Patch1 - Cross-correlation with no normalization (a)



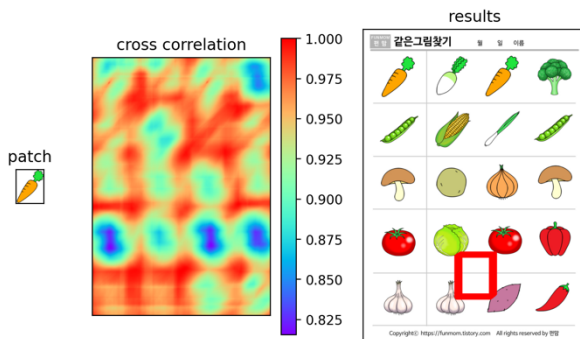
Patch1 - Cross-correlation with reverse N (b)



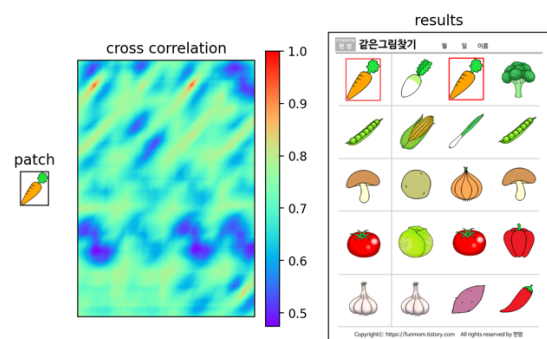
Patch2 - Cross-correlation with reverse N (c)



Patch3 - Cross-correlation with reverse N (d)




Patch1 - Cross-correlation with pixel N (e)

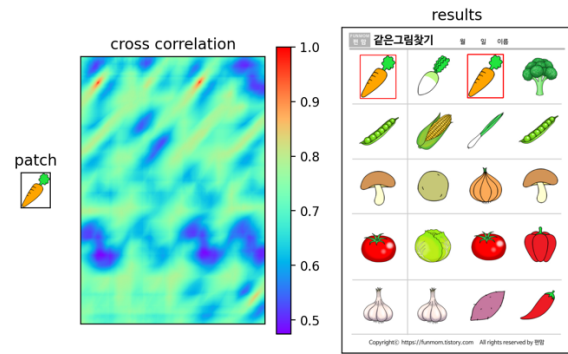


Patch1 - Cross-correlation with subtract N (f)

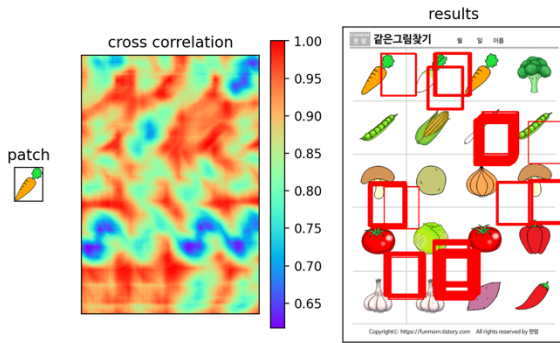
그림 3. Results – 1




Patch2 - Cross-correlation with reverse, subtract N (a)



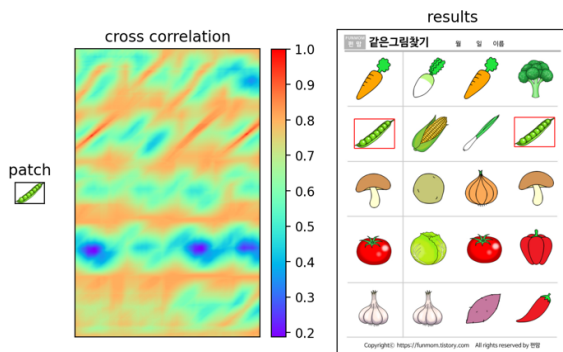
Patch3 - Cross-correlation with pixel, subtract N (b)



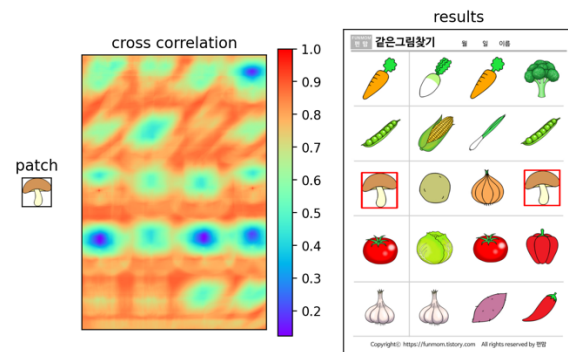
Patch1 - Convolution with subtract N (c)



Patch3 - Convolution with subtract N (d)



Patch2 – Cross-correlation with subtract N (e)



Patch3 – Cross-correlation with subtract N (f)

4.1 테스트 용어 및 목표

그림 3, 4 에서 명시된 **Patch 1, 2, 3** 은 **그림 2** 의 **(a), (b), (c)**에 대응한다. 또한 그림 3, 4 에서 명시된 **N** 이란 **Normalization** 으로, **정규화를 의미**한다. 각각의 정규화는 모두 `normalize.py` 에 있는 함수로 구현되었다. 정규화의 대상은 **도메인 이미지와 패치 이미지**이며, 결과를 표시할 때에는 원본 이미지를 출력하도록 하였다.

이미지 객체 검출에서 Cross-correlation 값을 활용하는데, 본 과제에서는 찾고자 하는 객체가 갖는 Cross-correlation 값을 **Objective value (목표 값)**로 칭한다. 원하는 객체 (patch) 가 아니지만 objective value 보다 높은 Cross-correlation 값을 갖는 영역을 **Upper error domain (상위 오류 영역)**라 정의하겠다. 이 과제물의 목표는 Upper error domain 을 없애고 Objective value 가 가장 높은 Cross-correlation value 가 되도록 하는 것이다.

4.2 정규화 처리를 하지 않은 경우

이미지에 아무런 전처리를 하지 않고 Cross-correlation 을 구했을 때 결과는 “같은 그림 찾기”를 수행하기에는 부적절했다. Cross-correlation 연산 수행 후 가장 높은 값은 흰색 부분이 많은 곳에 분포하기 때문이다. 따라서 패치의 객체모양대로 흰 픽셀이 존재하는 곳만 검출되었다. 그림 3 (a) 를 보면 그림 2 (a)의 객체 모양대로 흰 배경 (255)값이 있는 것을 확인할 수 있다.

4.3 이미지 반전

Patch 를 찾을 도메인 이미지가 전체적으로 흰 부분이 많으므로 이미지를 반전 시켰을 때 정확도를 더 높일 것이라 기대할 수 있다. 그림 3 (b), (c)에서는 실제로 객체를 잘 찾는 모습이나, 그림 3 (d)에서는 다른 객체를 표시하고 있다. 이는 이미지를 반전 시켜도 그 이미지에서 밝은, 혹은 픽셀 값이 높은 지역에 Cross-correlation 값이 높게 분포

하기 때문이다. 따라서 단순히 이미지를 반전시키는 것만으로는 근본적인 해결책이 될 수 없다.

4.4 픽셀 정규화

픽셀 정규화는 이미지의 모든 값을 해당 이미지의 높이 * 너비 값으로 나누는 연산이다. 픽셀 정규화는 객체 검출의 성능을 올려주진 않지만, Upper error domain 과 Objective value 간 차이를 줄여줄 수 있다. 그림 3 (e) 에서 threshold 보다 높은 값이 그림 3 (a) 보다 적은 영역에서 드러나지만 여전히 Error domain 에 객체를 검출하고 있다.

4.5 픽셀 평균값 정규화

모든 픽셀의 값은 0 ~ 255 사이의 값을 가지며 그 평균값은 약 128 이다. Cross-correlation 은 모든 픽셀을 element-wise 하게 곱하고 더하는 연산이기 때문에 이미지가 유사하지 않을 때 **음수**를 더하여 패널티를 만들어주는 것이 이상적이다. 가장 간단한 방법은 모든 이미지 픽셀에 픽셀 평균값 (128)을 빼주어 **음수 영역**을 만들어주는 것이다. 그림 3 의 (f), 그림 4 의 (a), (b) 에서 보이듯이, 픽셀 평균값 정규화를 하면 모두 Cross-correlation 값이 general 하게 나오며, Upper error domain 이 없이 성공적으로 객체 검출을 할 수 있다.

4.6 Convolution 적용하기

많은 경우에 이미지 검출에서 일반적으로 convolution 을 사용한다. 본 과제에서는 patch 를 좌우 반전하여 convolution 값을 계산하였다. 하지만 도메인 이미지에서는 모든 객체들이 정렬되어 있으며 아무런 회전, 크기 변화, 반전 등의 transform 이 없으므로 Cross-correlation 을 사용하는 것이 일반적으로 더 높은 정확도를 보여준다. 그림 4 의 (c) 에서 픽셀 평균값 정규화를 적용하였음에도 이미지의 흰 픽셀이 존재하는 곳만 찾아내거나, 패치의 일부분만 겹치는 곳을 검출하고 있다. 하지만 그림 4 (d) 와 같이 패치가 좌우 대칭인 특별한 경우 성공적으로 객체를 검출한다.

V. 논의

본 과제에서는 Cross-correlation (Convolution 의 경우 반전된 패치와 도메인의 Cross-correlation) 의 값이 저장된 output 에서 일정 threshold 값 이상에만 bounding box 를 표시했다. 이는 Output 별로 구체적으로 값을 설정해야 한다는 점에서 일반적이지 않다. Threshold 값을 설정하지 않고 상위 10 개의 위치를 찾는 방법처럼 특정 값에 의존하지 않도록 하는 것이 향후 개선 방안이라 할 수 있다.

VI. 결론

6.1 유의미한 정규화

그림 3 (f), 그림 4 (a), (b) 가 나타내듯, 픽셀 평균 값 정규화를 제외하고 모두 다른 정규화를 했음에도 불구하고, 모두 동일한 output 이 나왔다. 이는 양수 범위 내에서 이미지를 scaling 하는 것 보다, 이미지 전체 내에서 픽셀의 median 값을 0 으로 만들어 음수와 양수 값을 만드는 것이 유의미한 Cross-correlation 값을 찾는데 더 중요한 요인임을 알 수 있다.

6.2 가장 성공적인 객체 검출 방법

가장 성공적인 “같은 모양 찾기” 방법은 이미지를 **픽셀 평균값 정규화를 한 후, Cross-correlation 을 구하는 것이다.** 그림 3 (f), 그림 4 (e), (f) 이 가장 이상적인 결과이다. 검출할 patch 부분만 값만 0.9 이상으로 값이 높고 나머지는 그 이하로 나오기 때문에 general 한 접근 방법이라 할 수 있다.